

Universidade do Minho

Escola de Engenharia

Licenciatura em Engenharia Informática

Unidade Curricular de Aprendizagem e Decisão Inteligentes

Ano Letivo de 2022/2023

Conceção de Modelos de Aprendizagem

Grupo 6

A94942 Miguel Velho Raposo
A97588 Joana Isabel Freitas Pereira
A91775 José Pedro Batista Fonte
A96326 Bernard Ambrósio Georges

13 de maio de 2023

Índice

Lista de Figuras	3
1 Introdução	4
2 Tarefa[A] - dataset de Renda	5
2.1 Modelo	5
2.2 Estudo dos dados	6
2.2.1 Estudo Inicial	6
2.3 Preparação dos dados	11
2.3.1 Objetivo 1 (Price)	11
2.3.2 Objetivo 2 (Room Type)	11
2.4 Modelação	12
2.4.1 Objetivo 1 (Price)	12
2.4.2 Objetivo 2 (Room_Type)	16
2.5 Avaliação	17
3 Tarefa[B] - dataset de Obesidade	18
3.1 Modelo	18
3.2 Estudo dos dados	18
3.2.1 Estudo Inicial	18
3.3 Preparação dos dados	23
3.3.1 Remoções	24
3.3.2 Modificações	24
3.4 Modelação	24
3.4.1 Classificação	25
3.4.2 Regressão	26
3.4.3 Redes Neurais	27
3.5 Avaliação	28
4 Conclusão	29

Lista de Figuras

2.1	Tarefa A - Modelo	5
2.2	Tarefa A - Exploração Dados - Bar Char	8
2.3	Tarefa A - Exploração Dados - Correlation	8
2.4	Tarefa A - Exploração Dados - Line Plot	9
2.5	Tarefa A - Exploração Dados - Crosstab	9
2.6	Tarefa A - Exploração Dados - Scatter Plot	10
2.7	Tarefa A - Redes Neurais - Scatter Plot	14
2.8	Tarefa A - Segmentação - Scatter Plot	15
2.9	Tarefa A - Segmentação - Box Plot	16
3.1	Tarefa B - Modelo	18
3.2	Tarefa B - Exploração de Dados - Box Plot	20
3.3	Tarefa B - Exploração de Dados - Correlation	21
3.4	Tarefa B - Exploração de Dados - Crosstab	21
3.5	Tarefa B - Exploração dos Dados - Bar Chart	22
3.6	Tarefa B - Exploração de Dados - Scatter Plot	22
3.7	Tarefa B - Preparação de Dados - Data Explorer Numeric	23
3.8	Tarefa B - Preparação de Dados - Data Explorer Nominal	23
3.9	Tarefa B - Classificação - Scatter Plot	25
3.10	Tarefa B - Regressão - Scatter-Plot	27

1 Introdução

O presente relatório descreve o trabalho prático realizado pelo Grupo 6 no âmbito da Unidade Curricular de Aprendizagem e Decisão Inteligentes, lecionada no curso de Licenciatura em Engenharia Informática durante o 2º Semestre do ano letivo 2022/2023.

O objetivo deste projeto consiste em extrair conhecimento de conjuntos de dados por meio da aplicação de modelos de aprendizagem abordados ao longo do semestre. O projeto foi dividido em duas fases distintas: na primeira fase, o grupo trabalhou com um conjunto de dados de escolha própria, disponível publicamente, enquanto na segunda fase, o grupo recebeu um conjunto de dados atribuído pela equipe docente da disciplina.

Para garantir uma análise organizada e completa, o grupo utilizou uma parte do método CRISP-DM (Cross Industry Standard Process for Data Mining). No entanto, as fases de estudo do negócio e de desenvolvimento foram ignoradas, pois não eram relevantes para o trabalho em questão.

Em cada uma das fases, o grupo explorou, explicou, analisou e preparou o conjunto de dados em questão. Além disso, os modelos foram configurados e executados utilizando a ferramenta *KNIME*. Após a execução dos modelos, os resultados foram cuidadosamente analisados e o conhecimento obtido foi extrapolado para obter informações significativas e relevantes.

O relatório a seguir apresentará em detalhe as etapas e os resultados de cada fase do projeto, destacando as conclusões alcançadas e as contribuições proporcionadas pelo uso de técnicas de aprendizagem e decisão inteligentes.

2 Tarefa[A] - dataset de Renda

2.1 Modelo




Figura 2.1: Tarefa A - Modelo

2.2 Estudo dos dados

2.2.1 Estudo Inicial

Na Tarefa[A] o grupo teve de escolher um *dataset* publicamente disponível, para isso, através do Kaggle, o grupo optou por um dataset ligado aos Airbnb em New York City, que contém os seguintes parâmetros:

- **Id** (Int) : identificação do alojamento;
- **Name** (String) : Nome do alojamento;
- **Host_id** (Int) : Identificação do hospedeiro;
- **Host_name** (String) : data e tempo do fim da partida;
- **Neighbourhood_group** (String) : vizinhança onde o alojamento esta localizado;
- **Neighbourhood** (String) : bairro do alojamento;
- **latitude** (Double) : Latitude da localidade do alojamento ;
- **longitude** (Double) : Longitude da localidade do alojamento ;
- **room_type** (String) : Tipo do quarto disponível para aluguel (Entire home/apt, Private room, Shared room);
- **minimum_nights** (Int) : mínimo de noites para o aluguel do alojamento;
- **number_of_reviews** (Int) : Quantidade de reviews disponiveis;
- **last_review** (String) : Ultimo review feito;
- **Price** (Int): Preço do alojamento;
- **reviews_per_month** (Double) : Reviews feitos por mês;
- **calculated_host_listings_count** (Int) : Quantas listagens que o hospedeiro tem;
- **availability_365** (int) : Disponibilidade do alojamento alongo do ano em dias(365 dias).

Analisando os diferentes parâmetros disponíveis no *dataset* o grupo tem dois objetivos: um deles é prever os preços dos arrendamento dos locais e outro é prever o tipo de quarto consoante os dados disponibilizados.

Inicialmente o grupo utilizou o nodo *CSV Reader* para carregar o ficheiro AB_NYC_2019.csv para o workflow do Knime para de seguida prosseguir para a sua análise.

Pré-Exploração e Mini-Tratamento de Dados

Tanto o uso do *Statistics* como do *Data Explorer* é importante antes do tratamento de dados pois ajuda a compreender os dados e identificar possíveis erros ou anomalias. Os dois nodos oferecem estatísticas descritivas, como a média, mediana, desvio padrão e até o top e o bottom de cada coluna. Com essas informações, é possível determinar o melhor método de tratamento dos dados para cada variável e identificar quais são as mais relevantes para o modelo final. O tratamento adequado dos dados é fundamental para se obter um modelo final mais preciso e confiável.

No processo de análise inicial dos dados, foram encontrados alguns problemas como valores discrepantes, inconsistências e valores ausentes através de nodos como o *Statistics*, *Data Explore* e *Box Plot*. Em particular, na coluna *last_review* foram encontrados 10052 valores ausentes, o que representa quase 1/4 dos dados. Para reduzir a perda de dados, optou-se por filtrar essa coluna usando o *Column Filter* e, de seguida, utilizar o nodo *Missing Values* para tratar os valores ausentes de outras colunas. Este nodo foi configurado para remover a linha caso o valor seja uma string e substituir pela média caso seja um número, o que possibilitou a uma melhor exploração dos dados. De seguida foram analisados os nodos utilizados para a exploração dos dados.

Box Plot

Através do *Box Plot* foi possível visualizar a distribuição de cada variável do *dataset* e identificar valores discrepantes, como *outliers* e padrões em diferentes grupos ou categorias.

Bar Chart

O *Bar Chart* é usado para visualizar a frequência de cada valor em uma variável categórica. É importante para entender a distribuição de variáveis categóricas. Através da seguinte figura é possível verificar o número de Airbnbs em cada bairro.




Figura 2.2: Tarefa A - Exploração Dados - Bar Char

Linear Correlation e Rank Correlation

O nodo *Linear Correlation* foi inicialmente utilizado para calcular a correlação entre as variáveis, porém, como muitas das variáveis continham *missing values*, essa correlação poderia não ser precisa. Por isso, foi decidido utilizar o *Rank Correlation*, que é mais robusto para lidar com esses dados em falta. O *Rank Correlation* avalia as correlações não lineares entre as variáveis, utilizando a ordenação dos valores em vez dos próprios valores. Isso torna o *Rank Correlation* menos sensível a valores discrepantes (*outliers*) e mais adequado para lidar com dados não normalmente distribuídos. Com isso, mediante o nível de correlação entre as colunas é possível selecionar quais devem ser mantidas ou excluídas do modelo, o que permitiu criar modelos mais precisos e confiáveis.




Figura 2.3: Tarefa A - Exploração Dados - Correlation

GroupBy e Line Plot

O grupo usou o *Group By* para agrupar os dados de acordo com o bairro (*neighbourhood*) e calcular a média dos preços para cada grupo. Em seguida, usou-se o *Line Plot* para visualizar como o preço médio variava em cada bairro. Este nodo é utilizado para criar um gráfico de linha que mostra como uma variável (preço, neste caso) muda em relação a outra (bairro).




Figura 2.4: Tarefa A - Exploração Dados - Line Plot

Crosstab

O nodo *Crosstab* é usado para criar uma tabela de contingência entre duas variáveis categóricas. É importante para entender como duas variáveis categóricas estão relacionadas e para identificar possíveis padrões. Assim ajuda a entender melhor os dados e a decidir quais as colunas que devem ser mantidas. O grupo achou pertinente usar a coluna *neighbourhood_group* e *room_type* de modo a perceber qual o tipo de quarto mais comum em cada bairro.

Cross Tabulation of room_type by neighbourhood_group

Frequency Row Percent	Bronx	Brooklyn	Manhattan	Queens	Staten Island	Total
Entire home/apt	308 1,5157%	8 159 40,1506%	9 962 49,0232%	1 742 8,5724%	150 0,7382%	20 321
Private room	524 2,9682%	7 990 45,2589%	6 303 35,703%	2 678 15,1694%	159 0,9006%	17 654
Shared room	43 5,0827%	290 34,279%	356 42,0804%	152 17,9669%	5 0,591%	846
Total	875	16 439	16 621	4 572	314	38 821

☒ Frequency
☐ Expected
☐ Deviation
☐ Percent
☒ Row Percent
☐ Column Percent
☐ Cell Chi-Square

Max rows: 10
Max columns: 10

Figura 2.5: Tarefa A - Exploração Dados - Crosstab

Color Manager e Scatter Plot

O *Color Manager* é usado para codificar as cores usadas no *Scatter Plot*, que é um gráfico bidimensional que mostra a relação entre duas variáveis. É importante para identificar possíveis correlações entre as variáveis. No nosso caso o grupo achou interessante usar as cores para identificar os diferentes tipos de quartos (Entire home/apt - verde; Private room- azul; Shared room - vermelho). De seguida, foi usado o *Scatter Plot* de modo a ser possível verificar a influência do preço no tipo de quarto e nas reviews. Através do gráfico mais à esquerda é possível verificar que preços mais altos coincidem com Entire home/apt e mais reviews com preços mais baixos. Posteriormente foi usado outro *Scatter Plot*, para ver a influência da latitude e longitude no tipo de quarto. Pelo gráfico à direita verifica-se que não parece ter qualquer tipo de relação.




Figura 2.6: Tarefa A - Exploração Dados - Scatter Plot

2.3 Preparação dos dados

De modo a corrigir algumas inconsistências encontradas, o grupo realizou uma série de alterações e remoções aos dados de modo a corrigir os problemas nos mesmos para permitir uma extração adequada das informações necessárias para modelo.

De modo a verificar o sucesso dessas alterações e a adequação da preparação dos dados, utilizamos novamente os nodos de *Statistics* e *Data Explorer*.

Dependendo do objetivo foi feita uma preparação dos dados um pouco diferente:

2.3.1 Objetivo 1 (Price)

Remoções

Inicialmente através do *Column Filter*, como dito anteriormente, o grupo removeu a coluna *last_review* devido aos imensos missing values.

Através do nodo *Rank Correlation* as colunas que tivessem uma correlação inferior a 0.1 com a coluna *price* foram identificadas como potenciais remoções. De seguida através de outros nodos já explicados na exploração de dados foram escolhidas as seguintes colunas para remoção: *name*, *host_id*, *host_name*, *neighbourhood*, *number_of_views*, *last_review*, *reviews_per_month*, *availability_365*

De seguida, através do *Row Filter* foram removidas as linhas que tinham valor 0 na coluna *price*.

Por fim, o grupo achou pertinente o uso do *Numeric Outliers* para remover alguns outliers.

Adição

A fim de explorar a influência da distância ao centro da cidade no preço, foi utilizado o nó *Java Snippet* para criar uma nova coluna (*Distância*), que mede a distância de cada Airbnb a um ponto central definido em Nova York (40.7829, -73.9654). Através do *Scatter Plot* foi possível verificar a influência da distância no preço final.

2.3.2 Objetivo 2 (Room Type)

Remoções

Inicialmente através do *Column Filter*, como dito anteriormente, o grupo removeu a coluna *last_review* devido aos imensos missing values.

Contudo depois da exploração dos dados, usando o *Rank Correlation*, o *Scatter Plot* e o *Crosstab*, para este tratamento de dados, o grupo achou pertinente remover as seguintes colunas: name, host_id, host_name, neighbourhood, number_of_views, last_review, reviews_per_month, availability_365, neighbourhood_group, latitude e longitude.

2.4 Modelação

De modo a realizar uma análise mais rigorosa dos dados, a modelação foi dividida em quatro partes distintas: classificação, regressão, redes neuronais e segmentação.

Esta abordagem permite-nos utilizar as técnicas mais adequadas para cada tipo de análise, de forma a obtermos resultados mais precisos e úteis para o nosso projeto.

2.4.1 Objetivo 1 (Price)

Regressão

O grupo começou por usar o *Normalizer* para normalizar os dados, com exceção à coluna *price* uma vez que é a variável de destino do modelo. Se a mesma fosse normalizada, isso iria afetar a capacidade do modelo de fazer previsões precisas sobre os preços das propriedades, uma vez que o *Scorer* ia estar a comparar valores desnormalizados do preço com valores normalizados da previsão. Contudo, a ação de normalização é importante para garantir que todas as variáveis tenham o peso ao criar os modelos.

Para a construção do modelo, foram utilizados diferentes learners, como Gradient Boosted Trees Learner (Regression), Random Forest Learner (Regression), Tree Ensemble Learner (Regression), Linear Regression Learner e Polynomial Regression Learner. Esses learners permitiram testar diferentes modelos de regressão e escolher o que melhor se adequava ao problema em questão.

No caso específico mencionado, infelizmente, obtivemos valores de métricas baixos. O modelo que apresentou o melhor desempenho foi o Gradient Boosted Trees Learner, que obteve um R^2 de 0,533 e um MAE de 32,209, por exemplo. Isso significa que esse modelo foi capaz de explicar cerca de 53,3% da variabilidade nos dados e teve um erro médio absoluto de 32,209 na previsão dos preços das propriedades.

Na tentativa de melhorar o modelo, o grupo decidiu usar o *x-Partitioner* e o *X-agregator* em vez do *Partitioning*. No entanto, mesmo efetuando algumas alterações como a mudança da estratégia de amostragem de aleatória para Stratified Sampling e o aumento do número de validações no Cross-validation não se verificou uma melhoria significativa na precisão do modelo.

Classificação

De modo a usarmos a previsão dos preços para um problema de classificação, o grupo optou por utilizar um *Auto-Binner* para fazer uma divisão dos preços por intervalos. De seguido foi utilizado o *Column Filter* para retirar a coluna price e o *Normalizer* para normalizar os dados, de modo a que todas as variáveis tenham a mesma escala. Isso é importante para garantir que todas as variáveis tenham o mesmo peso ao criar modelos.

Para criar os modelos mencionados acima, os nodos de *Partitioning* foram usados para dividir o conjunto de dados em subconjuntos de treinamento e teste, garantindo que o modelo não fosse treinado e testado no mesmo conjunto de dados, o que poderia levar a uma superestimação do desempenho do modelo. A partição dos dados foi feita em 65-35 e foi usado linear sampling.

De seguida, foram usados vários *learners* (Decision Tree Learner, Random Forest Learner, e o Gradient Boosted Trees Learner) com os seus respetivos *predictors* com o objetivo de usar o nodo *Scorer* para verificar qual seria o melhor a usar consoante os dados disponíveis. Infelizmente todos tiveram uma precisão baixa, a rondar os 50%. O grupo ainda tentou fazer alterações em alguns dos hiperparâmetros mas a diferença foi pouca.

Na tentativa de melhorar o modelo, o grupo decidiu usar o *x-Partitioner* e o *X-agregator* em vez do *Partitioning*. Depois de efetuar algumas alterações como a mudança da estratégia de amostragem de aleatória para Random Sampling e com o número de validações no Cross-validation a 10, entre outras, mas não se verificou uma diferença significativa.

Redes neuronais

Para o uso deste tipo de modelo foi necessário fazer um pequeno tratamento de dados. Para isso, o grupo utilizou o nodo *Rule Engine* para alterar as colunas, modificando as strings para números inteiros. As seguintes colunas foram alteradas:

- **room_type:**
 - Private Room → 1
 - Shared Room → 0
 - Entire home/apt → 2
- **neighbourhood_group:**
 - Brooklyn → 3
 - Manhattan → 2
 - Queens → 1
 - Bronx → 0

De seguida normalizou-se os dados e fez-se a partição dos mesmos.

Usando o *RProp MPL Lerner*, o respetivo predictor e alguns nodos como o *Numeric Scorer* e o *Scatter Plot* foi possível interpretar o desempenho das redes neurais. Os resultados obtidos foram semelhantes aos já verificados anteriormente.

É de salientar que o grupo teve alguma dificuldade nesta parte, uma vez que a normalização da coluna escolhida (price), teve impacto em um resultado negativo no *Numeric Scorer*. Porém o *RProp MPL Lerner* só aceita valores entre 0 e 1, pelo que a coluna tem de ser normalizada. Infelizmente a única solução encontrada foi o uso do *Numeric Scorer* antes da desnormalização os dados, apesar de parecer incorreto.

Através do seguinte gráfico é possível verificar a influência da distância e do tipo de quarto na previsão do preço. (Entire home/apt - verde, Private room - castanho, Shared room - vermelho)




Figura 2.7: Tarefa A - Redes Neurais - Scatter Plot

Segmentação

O grupo achou que poderia ser interessante usar a segmentação para dividir os dados em clusters que teriam em conta a distância e o preço dos apartamentos. Assim seria possível prever essas categorias através de alguns nodo de classificação.

Para isso, inicialmente usou-se a regra do cotovelo. Porém, dava muitos clusters (12) e optou-se por usar apenas 6 de modo a representar as seguintes categorias: topCenter, mediumCenter, lowCenter, lowSuburb, mediumSuburb, topsuburb.

Depois da desnormalização dos dados, do uso do *K-Means*, do respetivo predictor *Cluster*

Assigner e do *Denormalizer* foi efetuada uma análise aos mesmos.

Para essa análise, de modo a perceber melhor como os clusters estavam divididos mediante a distância e o preço, foram usados vários nodos como o *Color Manager*, *Scatter Plot*, *Parallel Coordinates Plot*, *Group By*, *Table View* e *Bar Chart*.

Através do gráfico abaixo é possível fazer a divisão por categorias já mencionada a cima através do nodo *Rule Engine*.




Figura 2.8: Tarefa A - Segmentação - Scatter Plot

Assim as cores atribuídas seriam as seguintes:

- **lowCenter** - castanho;
- **lowSuburb** - roxo;
- **mediumCenter** - laranja;
- **mediumSuburb** - vermelho;
- **topCenter** - verde;
- **topSuburb** - azul

Por fim, foi usado o *Partitioning*, *Decision Tree Learner* e o *Decision Tree Predictor* para avaliar o modelo quantos às categorias criadas. Para isso foram usados nodos como o *Box Plot* e o *Scorer*. Uma vez que a precisão do modelo foi bastante alta (99,2%), o grupo ficou contente com os resultados e considerou que a divisão dos clusters foi bem sucedida.

Pela figura seguinte é possível visualizar que os preços são influenciados pela distância ao centro:




Figura 2.9: Tarefa A - Segmentação - Box Plot

2.4.2 Objetivo 2 (Room_Type)

Classificação

O grupo começou por usar o *Normalizer* para normalizar os dados, de modo a que todas as variáveis tenham a mesma escala. Isso é importante para garantir que todas as variáveis tenham o mesmo peso ao criar modelos.

De seguida, foi usado um nodo de *Partitioning* para dividir o conjunto de dados em subconjuntos de treinamento e teste, garantindo que o modelo não fosse treinado e testado no mesmo conjunto de dados, o que poderia levar a uma superestimação do desempenho do modelo. A partição dos dados foi feita em 60-40 e foi usado stratified sampling, usando um random seed aleatória.

Posteriormente, foram usados vários *learners* (Decision Tree Learner e o Gradient Boosted Trees Learner) com os seus respetivos *predictors* com o objetivo de usar o nodo *Scorer* para verificar qual seria o melhor a usar consoante os dados disponíveis. O que se destacou mais foi o Gradient Boosted Tree Learner, mas sem uma diferença muito significativa. No primeiro, foi efetuada uma alteração na medida de qualidade, foi alterada do *Gain Ratio* para o *Gini Index* de modo a melhorar a precisão do modelo, já que o segundo é mais adequado para dados com classes desequilibradas. A precisão dos modelos foi por volta dos 80%, um valor bastante aceitável.

Redes Neurais

Para este caso não foi preciso fazer um tratamento de dados complexo, uma vez todas as colunas, sem contar com a escolhida para a previsão, já se encontravam em double. Foi apenas necessário normalizar os dados.

De seguida, usando o *Partitioning*, o *RProp MPL Learner*, o respetivo predictor e alguns nodos como o *Numeric Scorer* e o *Scatter Plot* foi possível interpretar o desempenho das redes neurais. Os resultados obtidos foram semelhantes aos já verificados anteriormente.

O grupo também tentou o uso do *DL4J Feedforward Learner (Classification)* juntamente com outros nodos, porém verificando a precisão através do nodo *Scorer* foi ligeiramente mais baixa (66% em comparação com os 81% do modelo passado)

2.5 Avaliação

É de ainda ressaltar que o *Decision Tree Learner* e o *Random Forest Learner* foram utilizados antes e depois do tratamento de dados para avaliar a eficácia do mesmo e comparar os modelos gerados.

No caso do primeiro, que tem em conta o objetivo2 (room type), as precisões dos modelos não sofreram uma diferença significativa. Isso pode dever-se ao facto de termos eliminado uma coluna importante para a previsão. Mas mantê-la também não seria uma boa opção, pois continha muitos missing values, o que iria a levar à perda de muitas linhas, também prejudicial para uma boa previsão. Apesar disso, o grupo considera que o tratamento de dados foi bem-sucedido e que os dados estão mais limpos e bem estruturados, o que leva a modelos mais precisos e confiáveis.

No segundo caso, tendo em conta que objetivo era prever o preço, as precisões dos modelos após o tratamento de dados, apesar de baixas, melhoraram nas várias métricas, como por exemplo de 0,2 para 0,5 no R2, pelo que o tratamento de dados foi bem-sucedido.

Assim pode concluir-se que mediante este *dataset*, e através das colunas que este contém a precisão para prever o tipo de quarto foi bem superior à de prever o preço dos Airbnbs.

3 Tarefa[B] - dataset de Obesidade

3.1 Modelo




Figura 3.1: Tarefa B - Modelo

3.2 Estudo dos dados

3.2.1 Estudo Inicial

Na Tarefa[B] o grupo tem de analisar e preparar um *dataset* que lhe foi atribuído, ligado à obesidade e que contém os seguintes parâmetros:

- **rowID** (int): id do registo;
- **Gender** (string): sexo da pessoa - Male/Female ;
- **Age** (string) : idade em anos;
- **Date_of_birth** (string) : data de nascimento (DD/MM/AAAA);
- **Height** (string): altura em metros;
- **Weight** (string) : peso em Kgs;
- **Family_history_with_overweight** (string) : histórico de obesidade na família - yes/no;
- **FAVC** (string): Consumo frequente de alimentos altamente calóricos - yes/no;
- **FCVC** (string): Frequência de consumo de vegetais - sometimes/always/never;
- **NCP** (string): Número de refeições (1-4);
- **CAEC** (string): Consumo de alimentos ente refeições - Sometimes/Frequently/Always/no;
- **SMOKE** (string): Se a pessoa fuma - yes/no
- **CH20** (string): Consumo diário de água (1= menos que 1 litro, 2= 1-2 litros, 3= mais que dois litros);
- **SCC** (string): Monitoramento do consumo de calorias - yes/no
- **FAF** (string): Frequência de atividade física (0-nenhuma, 1= 1-2 dias, 2= 2-4 dias, 3= 4-5 dias);
- **TUE** (string): Tempo usado em dispositivos tecnológicos (0= 0-2 horas, 1= 3-5 horas, 2= mais que 5 horas;
- **CALC** (string): Consumo de alcool - Sometimes/no/Frequently/Always;
- **MITRANS** (string): Transporte usado -Public_Transportation/Automobile/Walking/MotorBike/Bike
- **NObeyesdas** (string): Nível de obesidade - Obesity_Type_I/Obesity_Type_III,/Obesity_Type_II, /Overweight_Level_I,/Overweight_Level_II,/Normal_Weight,/Insufficient_Weight

Analisando os diferentes parâmetros disponíveis no *dataset* o grupo tem como objetivo prever o tipo de obesidade consoante os dados disponibilizados.

Inicialmente o grupo utilizou o nodo *CSV Reader* para carregar o ficheiro *obesidade.csv* para o workflow do *Knime* para de seguida prosseguir para a sua análise.

Pré-Exploração e Mini-Tratamento de Dados


Tanto o uso do *Statistics* como do *Data Explorer* é importante antes do tratamento de dados pois ajuda a compreender os dados e identificar possíveis erros ou anomalias. Os dois nodos oferecem estatísticas descritivas, como a média, mediana, desvio padrão e até o máximo e o mínimo de cada coluna. Com essas informações, é possível determinar o melhor método de tratamento dos dados para cada variável e identificar quais são as mais relevantes para o modelo final. O tratamento adequado dos dados é fundamental para se obter um modelo final mais preciso e confiável.

Através deste nodos foram identificadas possíveis conversões necessárias de modo a ser possível a utilização de outros plots para uma melhor análise dos dados. Utilizando o nodo *String to Number* algumas colunas foram convertidas de *String* para *Double* (Age, Height, Weight, NCP, FAF) para atender ao formato desejado do modelo. Em seguida, utilizando o nodo *Round Double* algumas colunas (Age, NCP, FAF) foram arredondadas para baixo com 0 casas decimais usando o "rounding mode - down". Para as variáveis height e weight, foi usado o "rounding mode - Half_even" e uma precisão de 2 para arredondar para o número mais próximo, com duas casas decimais.


Foram ainda verificados dados danificados na coluna *FCVC* que através do nodo *Java Snippet* foram corrigidos para poder haver uma melhor análise da mesma.

Box Plot

Através do *Box Plot* foi possível visualizar a distribuição de cada variável do *dataset* e identificar valores discrepantes, como *outliers* e padrões em diferentes grupos ou categorias.



(a) Original



(b) Normalizado

Figura 3.2: Tarefa B - Exploração de Dados - Box Plot

Linear Correlation e Rank Correlation

O nodo *Linear Correlation* foi inicialmente utilizado para calcular a correlação entre as variáveis, porém, como muitas das variáveis continham *missing values*, essa correlação poderia não ser precisa. Por isso, foi decidido utilizar o *Rank Correlation*, que é mais robusto para lidar com esses dados em falta. O *Rank Correlation* avalia as correlações não lineares entre as variáveis, utilizando a ordenação dos valores em vez dos próprios valores. Isso torna o *Rank Correlation* menos sensível a valores discrepantes (*outliers*) e mais adequado para lidar com dados não normalmente distribuídos. Com isso, mediante o nível de correlação entre as colunas é possível selecionar quais devem ser mantidas ou excluídas do modelo, o que permitiu criar modelos mais precisos e confiáveis.




Figura 3.3: Tarefa B - Exploração de Dados - Correlation

Crosstab

O nodo *Crosstab* é usado para criar uma tabela de contingência entre duas variáveis categóricas. É importante para entender como duas variáveis categóricas estão relacionadas e para identificar possíveis padrões. Assim ajuda a entender melhor os dados e a decidir quais as colunas que devem ser mantidas. Um exemplo do seu uso foi com as colunas *TUE* e *NObesydad* para perceber a relação entre ambas.

Cross Tabulation of TUE by NObesydad

Frequency Row Percent	Insufficient_Weight	Normal_Weight	Obesity_Type_I	Obesity_Type_II	Obesity_Type_III	Overweight_Level_I	Overweight_Level_II	Total
0.0	133 9,3993%	129 9,1166%	221 15,6184%	231 16,3251%	312 22,0495%	204 14,417%	185 13,0742%	1 415
1.0	120 20,4429%	122 20,7836%	105 17,8876%	64 10,9029%	12 2,0443%	70 11,925%	94 16,0136%	587
2.0	19 17,4312%	36 33,0275%	25 22,9358%	2 1,8349%		16 14,6789%	11 10,0917%	109
Total	272	287	351	297	324	290	290	2 111

Figura 3.4: Tarefa B - Exploração de Dados - Crosstab

Bar Chart

O *Bar Chart* é usado para visualizar a frequência de cada valor em uma variável categórica. É importante para entender a distribuição de variáveis categóricas. Através da seguinte figura é possível verificar o número de pessoas em cada nível de obesidade.




Figura 3.5: Tarefa B - Exploração dos Dados - Bar Chart

Color Manager e Scatter Plot

O *Color Manager* é usado para codificar as cores usadas no *Scatter Plot*, que é um gráfico bidimensional que mostra a relação entre duas variáveis. É importante para identificar possíveis correlações entre as variáveis. No nosso caso o grupo achou interessante usar as cores para identificar os diferentes tipos de obesidade para de seguida usando o *Scatter Plot* ser possível ver a influência de uma forma mais clara do peso e da altura no nível de obesidade.




Figura 3.6: Tarefa B - Exploração de Dados - Scatter Plot

3.3 Preparação dos dados

De modo a corrigir as algumas inconsistências encontradas, o grupo realizou uma série de alterações e remoções aos dados de modo a corrigir os problemas nos mesmos para permitir uma extração adequada das informações necessárias para modelo.

De modo a verificar o sucesso dessas alterações e a adequação da preparação dos dados, utilizamos novamente os nodos de *Statistics* e *Data Explore*.

Column	Exclude Column	Minimum	Maximum	Mean	Standard Deviation	Variance	Skewness	Kurtosis
Age	☐	14	61	23.973	6.309	39.799	1.562	2.989
Height	☐	1.450	1.980	1.702	0.093	0.009	-0.009	-0.565
Weight	☐	39	173	86.586	26.191	685.977	0.255	-0.700
NCP	☐	1	4	2.523	0.830	0.689	-0.885	-0.457
FAF	☐	0	3	0.735	0.833	0.694	0.899	0.004

Figura 3.7: Tarefa B - Preparação de Dados - Data Explorer Numeric

Column	Exclude Column	No. missings	Unique values	All nominal values	Frequency Bar Chart
family_history_with_overweight	☐	0	2	yes, no	
CAEC	☐	0	4	Sometimes, Frequently, Always, no	
CALC	☐	0	4	Sometimes, no, Frequently, Always	
NObeyesdad	☐	0	7	Obesity_Type_I, Obesity_Type_III, Obesity_Type_II, Overweight_Level_I, Overweight_Level_II, Normal_Weight, Insufficient_Weight	

Figura 3.8: Tarefa B - Preparação de Dados - Data Explorer Nominal

3.3.1 Remoções

Através do *Rank Correlation* foi possível identificar as potenciais tabelas a serem removidas, através da fraca correlação entre as variáveis (foram escolhidas as que tinham correlação abaixo de 0.1) e de seguida através do *CrossTab* foi verificada se faria sentido essa remoção. Houve apenas uma exceção, no caso do *TUE*, apesar da correlação ser de 0,2 através do *CrossTab* o grupo achou que faria sentido a sua remoção.

Foi ainda decidido a remoção da coluna *Date_of_birth*. Esta remoção deve-se ao facto de já haver uma coluna com a idade do indivíduo e essa ter uma maior correlação com a coluna *NObeyesdas*.

Dito isto as tabelas que foram removidas foram as seguintes: Gender, FCVC, SMOKE, CH20, FACV, SCC, MTRANS, TUE, Date_of_birth.

3.3.2 Modificações

Em alguns dos campos do *dataset* o grupo teve de recorrer a alterações no mesmo de modo a facilitar a sua análise. As modificações foram realizadas através do nodo *Rule Engine*. As colunas que foram alteradas foram as seguintes:

- **CAEC**: Correção da palavra "sometymes" para "Sometimes";
- **CALC**: Correção da palavra "Frequently" para "Frequently";

3.4 Modelação

De modo a realizar uma análise mais rigorosa dos dados, a modelação foi dividida em três partes distintas: classificação, regressão e redes neuronais.

Na parte de classificação, o objetivo é categorizar os dados de acordo com determinados critérios, na parte de regressão o grupo procurou encontrar relações entre variáveis e fazer previsões numéricas e através das redes neuronais o grupo procura explorar a capacidade dos modelos em lidar com problemas complexos e capturar relações não lineares nos dados, contribuindo assim para uma análise mais abrangente e aprimorada do conjunto de dados do nosso projeto.

Esta abordagem permite-nos utilizar as técnicas mais adequadas para cada tipo de análise, de forma a obtermos resultados mais precisos e úteis para o nosso projeto.

3.4.1 Classificação

O grupo começou por usar o *Normalizer* para normalizar os dados, de modo a que todas as variáveis tenham a mesma escala. Isso é importante para garantir que todas as variáveis tenham o mesmo peso ao criar modelos.

De seguida, foi usado um nodo de *Partitioning* para dividir o conjunto de dados em subconjuntos de treinamento e teste, garantindo que o modelo não fosse treinado e testado no mesmo conjunto de dados, o que poderia levar a uma superestimação do desempenho do modelo. A partição dos dados foi feita em 75-25 e foi usado stratified sampling, usando um random seed aleatória.

Posteriormente, foram usados vários *learners* (Decision Tree Learner, Random Forest Learner, Tree Ensemble Learner e o Gradient Boosted Trees Learner) com os seus respetivos *predictors* com o objetivo de usar o nodo *Scorer* para verificar qual seria o melhor a usar consoante os dados disponíveis. Os que se destacaram mais foi o o Decision Tree Learner o Gradient Boosted Tree Learner. No primeiro, foi efetuada uma alteração na medida de qualidade, foi alterada do *Gain Ratio* para o *Gini Index* de modo a melhorar a precisão do modelo, já que o segundo é mais adequado para dados com classes desequilibradas. No Gradient Boosted Tree Learner, devido a ser o modelo com melhor performance, para além do *Scorer*, foi usado o nodo *Scatter Plot* para verificar que as previsões estão próximas dos valores reais, pois os pontos no scatter plot estão alinhados próximos a uma linha diagonal, à exceção de alguns.




Figura 3.9: Tarefa B - Classificação - Scatter Plot

X-Partitioner e X-Aggregator

Na tentativa de melhorar o modelo, o grupo decidiu usar o *x-Partitioner* e o *X-aggregator* em vez do *Partitioning*. Depois de efetuar algumas alterações como a mudança da estratégia de amostragem de aleatória para Stratified Sampling e o aumento do número de validações no Cross-validation verificou-se uma pequena melhoria na precisão, mas nada de significativa.

Logistic Regression

O algoritmo de regressão logística é uma técnica de aprendizagem supervisionada para prever a probabilidade de uma variável binária. No entanto, como a variável selecionada não era binária, utilizamos o nodo *Rule Engine* para criar uma nova coluna chamada **Obesidade**.

Essa nova coluna foi criada com base na análise da coluna *NObeyesdas*, onde os indivíduos com obesidade foram classificados como "sim" e os restantes como "não". Em seguida, utilizamos o nodo *Column Filter* para remover a coluna *NObeyesdas* e normalizamos os dados.

Por fim, utilizamos o *Logistic Regression Learner* com o predictor correspondente para realizar a análise de regressão logística nos dados normalizados e o *ROC Curve* e o *Scorer* para avaliar a qualidade do modelo obtido. Como era de esperar teve uma precisão bastante elevada, de 99,8%, apenas errando em uma classificação

3.4.2 Regressão

O grupo começou por recorrer ao nodo *Java Snippet*, que permitiu a criação de uma nova coluna numérica denominada de índice de massa corporal (IMC). Esse índice foi calculado a partir da altura e do peso de cada indivíduo, transformando assim o objetivo em um problema de regressão, onde a meta é prever o valor do IMC com base nas variáveis.

No entanto, após uma análise exploratória utilizando o *Scatter Plot*, o grupo percebeu que indivíduos com valores de IMC similares eram classificados com diferentes tipos de obesidade.

Nesse sentido, optou-se por criar uma nova tabela contendo a classificação da obesidade com base no IMC, para comparar os resultados. Utilizando o *Scorer*, foi possível verificar que o modelo tinha uma precisão de 80%, indicando que alguns indivíduos estavam mal classificados.

Para a construção do modelo, foram utilizados diferentes learners, como Gradient Boosted Trees Learner (Regression), Random Forest Learner (Regression), Tree Ensemble Learner (Regression), Linear Regression Learner e Polynomial Regression Learner. Esses learners permitiram testar diferentes modelos de regressão e escolher o que melhor se adequava ao problema em questão.

No caso específico mencionado, embora os valores das métricas tenham sido todos bons, o




Figura 3.10: Tarefa B - Regressão - Scatter-Plot

modelo que apresentou o melhor desempenho foi o Gradient Boosted Trees Learner, que obteve um R^2 de 0,995 e um MAE de 0,411, entre outros valores bons. Isso indica que esse modelo foi capaz de explicar 99,5% da variação dos dados, e teve um erro médio absoluto de apenas 0,411 unidades, o que é considerado um bom desempenho.

3.4.3 Redes Neurais

Para o uso deste tipo de modelo foi necessário fazer um pequeno tratamento de dados. Para isso, o grupo utilizou o nodo *Rule Engine* para alterar as colunas, modificando as strings para números inteiros. As seguintes colunas foram alteradas:

- **family_history_with_overweight**: Alterado de "yes" para 1 e "no" para 0;
- **CAEC e CALC**:
 - Always → 3
 - Sometimes → 1
 - Frequently → 2
 - no → 0

De seguida normalizou-se os dados e fez-se a partição dos mesmos. Usando o *RProp MPL Lerner*, o respetivo predictor e alguns nodos como o *Scorer* e o *Scatter Plot* foi possível interpretar o desempenho das redes neurais na classificação da obesidade. Os resultados obtidos foram bons mas parecidos aos já verificados anteriormente.

3.5 Avaliação

É de ainda ressaltar que o *Decision Tree Learner* foi utilizado antes e depois do tratamento de dados para avaliar a eficácia do mesmo e comparar os modelos gerados. Foi identificado uma grande discrepâncias entre estes visto que o *learner* utilizado após o tratamento possui uma precisão bastante maior que o da sua previsão anterior (60%). O que prova que o tratamento de dados foi bem-sucedido e que os dados estão mais limpos e bem estruturados, o que leva a modelos mais precisos e confiáveis.

4 Conclusão

A realização deste trabalho proporcionou ao grupo uma oportunidade de aplicar os conhecimentos teóricos adquiridos em um contexto real, enfrentando desafios e tomando decisões sobre a seleção e implementação dos modelos de aprendizagem.

Em algumas partes foram sentidas algumas dificuldades na seleção e implementação de alguns modelos, mas estas foram ultrapassadas e o grupo ficou satisfeito com o trabalho desenvolvido.

Assim, a realização do projeto contribuiu para a consolidação de conhecimentos prévios e para a aquisição de novas habilidades.